

## 改进的核相关滤波器目标跟踪算法

余礼杨\*, 范春晓, 明悦

(北京邮电大学 电子工程学院, 北京 100876)

(\* 通信作者电子邮箱 yuliyang@qq.com)

**摘要:** 针对传统单目标的核相关滤波器(KCF)跟踪算法在目标尺度变化的跟踪中存在的问题,提出了一种基于相关滤波器(CF)和尺度金字塔的多尺度核相关滤波器(SKCF)跟踪算法。首先通过传统KCF跟踪算法中分类器的响应计算当前目标是否受到遮挡,在未受到遮挡的情况下,对当前目标建立尺度金字塔;然后通过相关滤波器求取尺度金字塔的最大响应得到当前目标尺度信息;最后使用新目标图像为训练样本更新目标的外观模型和尺度模型。与核化的结构化输出(Struck)算法、KCF算法、跟踪-学习-检测(TLD)算法和多示例学习(MIL)算法进行对比,实验结果表明,所提出的多尺度核相关滤波器(SKCF)跟踪算法在五种算法中精确度和重合度都取到最高值。所提算法能够广泛应用于目标跟踪领域,对目标进行准确的跟踪。

**关键词:** 目标跟踪; 多尺度; 相关滤波器; 判别模型; 遮挡检测

**中图分类号:** TP391.4 **文献标志码:** A

### Improved target tracking algorithm based on kernelized correlation filter

YU Liyang\*, FAN Chunxiao, MING Yue

(School of Electronic Engineering, Beijing University of Posts and Telecommunications, Beijing 100876, China)

**Abstract:** Focusing on the issue that the Kernelized Correlation Filter (KCF) tracking algorithm has poor performance in handling scale-variant target, a multi-scale tracking algorithm called Scale-KCF (SKCF) based on Correlation Filter (CF) and multi-scale image pyramid was proposed. Firstly, the occlusion status of the target was got through the response of the conventional KCF algorithm's classifier. The multi-scale image pyramid was built for the occluded target. Secondly, the scale information of the target was obtained by calculating the correlation filter's maximum response on the multi-scale image pyramid. Finally, the appearance model and the scale model of the target were updated with the fresh target. The experimental results on comparison with some state-of-the-art trackers such as Structured Output tracking with kernel (Struck), KCF, Tracking-Learning-Detection (TLD) and Multiple Instance Learning (MIL) demonstrate that the proposed tracker of SKCF achieves the best accuracy and overlap rate than other algorithms. Meanwhile, the proposed tracker can be widely used in target tracking and achieve high precise target tracking.

**Key words:** target tracking; multi-scale; Correlation Filter (CF); discriminative model; occlusion detection

## 0 引言

目标跟踪是计算机视觉领域里的基础性问题,在现实生活中应用广泛,如视频监控、人机交互、智能汽车等<sup>[1]</sup>。虽然在过去的二十年里,目标跟踪取得了巨大的进展,但由于光照变化、目标受到部分或全部遮挡、目标的形变等因素影响,精确的目标跟踪算法仍然难以实现。

近年来,基于判别方法的单目标跟踪算法显著提升了跟踪的性能。目前比较流行的单目标跟踪算法有基于核化的结构化输出(Structured output tracking with kernel, Struck)<sup>[2]</sup>算法、跟踪-学习-检测(Tracking-Learning-Detection, TLD)<sup>[3]</sup>算法、多示例学习(Multiple Instance Learning, MIL)<sup>[4]</sup>算法、压缩感知(Compressive Tracking, CT)<sup>[5]</sup>算法等,这些跟踪算法将目标跟踪视为二值分类问题,通过对上一帧图像中的目标周围进行有限数量的样本选取并将这些样本划分成正负样本集来训练得到一个分类器,然后使用分类器对候选样本进行概率评估,概率最高的候选样本即为目标。然而考虑到训练

样本的过程非常耗费时间,为达到实时目标跟踪效果,这些算法通常选取的训练样本和候选样本数量有限,导致训练得到的分类器模型不能够充分利用跟踪目标及其周围背景图像信息。Bolme等<sup>[6]</sup>提出了最小输出平方误差和(Minimum Output Sum of Squared Error, MOSSE)跟踪算法,该算法只需要一个目标区域样本图像训练目标外观模型,通过离散傅里叶变换将目标与所有候选区域之间的相似度计算转换到频域,显著地提升了跟踪算法的运行速度。然而MOSSE算法同样也只选择数量有限的候选样本训练分类器模型。时空上下文(Spatio-Temporal Context, STC)<sup>[7]</sup>跟踪算法将目标周围的背景信息加入到卷积滤波器模型的训练当中,以减弱部分遮挡对目标的影响。Henriques等<sup>[8]</sup>提出了循环结构的检测跟踪(Circulant Structure of tracking-by-detection with Kernel, CSK)算法对训练样本进行循环移位,从而近似为对目标的密集采样,得到大量的训练本来训练分类器,同时对候选样本同样采用循环移位,构造大量的候选区域用于分类器的检测过程,并且分类器的训练和检测过程都可以利用离散傅里叶

收稿日期: 2015-05-28; 修回日期: 2015-08-21。 基金项目: 国家自然科学基金资助项目(61402046)。

作者简介: 余礼杨(1991-),男,浙江苍南人,硕士研究生,主要研究方向: 图像处理、目标检测、目标跟踪; 范春晓(1962-),女,辽宁抚顺人,教授,博士生导师,主要研究方向: 图像处理、数据挖掘; 明悦(1984-),女,北京人,讲师,博士,主要研究方向: 人脸识别、三维重建。

变换在频域实现快速计算。Danelljan 等<sup>[9]</sup>在 CSK 的基础上,引入了颜色空间特征<sup>[10]</sup>,并且采用主成分分析(Principal Components Analysis, PCA)将 11 维的颜色空间特征向量降到了 2 维,提升了跟踪器的运行速度和精确度。Li 等<sup>[11]</sup>对训练样本图像进行 5 个尺度空间上的缩放,在尺度空间上求取分类器最大响应,从而解决了 CSK 不能有效对有尺度变化的目标进行跟踪的问题,然而速度却降为原来的五分之一。核相关滤波器(Kernelized Correlation Filter, KCF)<sup>[12]</sup>跟踪算法在 CSK 的基础上,使用方向梯度直方图(Histogram of Oriented Gradient, HoG)<sup>[13]</sup>特征代替原来的灰度值特征。然而,传统的 KCF 跟踪算法与 CSK 算法有同样的问题,即无法有效处理目标运动中出现的尺度变化。

针对目标运动过程中出现的尺度变化问题,本文结合相关滤波器(Correlation Filter, CF)和尺度金字塔图像对 KCF 跟踪算法进行改进,提出了一种多尺度核相关滤波器(multi-Scale Kernelized Correlation Filter, SKCF)跟踪算法。同时,本文还提出一种遮挡检测机制用于降低遮挡对尺度估计过程的影响。当目标受到遮挡时,在停止对目标进行尺度估计的同时停止对分类器模型的更新,从而提高跟踪算法的准确度和稳定性。

## 1 KCF 跟踪算法

KCF 跟踪算法的核心思想是将跟踪目标区域进行循环移位,以此构造大量的样本来训练分类器。通过核函数来计算候选区域与跟踪目标的相似程度,选取相似度最大的候选区域为新的跟踪目标,同时利用离散傅里叶变换降低分类器训练和检测过程中的运算量。

### 1.1 训练样本集合

KCF 算法中的分类器训练过程只需要一张目标区域的样本图像  $x$ , 记  $x$  是  $1 \times n$  的向量。与其他基于判别方法的目标跟踪算法不同的是,在分类器的训练过程中, KCF 并不严格区分正样本和负样本。

使用置换矩阵  $P$  对唯一的的目标区域样本图像进行循环移位,得到训练样本集合  $\{P^i x \mid i = 0, 1, \dots, n-1\}$ 。其中:

$$P = \begin{bmatrix} 0 & 0 & \cdots & 0 & 0 & 1 \\ 1 & 0 & \cdots & 0 & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & 0 & 0 \\ 0 & 0 & \cdots & 0 & 1 & 0 \end{bmatrix} \quad (1)$$

记  $X_i$  为循环移动  $i$  位后的训练样本,  $X_i = P^i x, \forall i = 0, 1, \dots, n-1$  构成循环矩阵  $X$ 。

$$X = C(x) = [X_0 \ X_1 \ \cdots \ X_{n-1}]^T \quad (2)$$

对于训练样本  $X_i$  赋予标签  $y_i$  ( $y_i$  值服从高斯分布)。

### 1.2 分类器训练

在 KCF 算法中,分类器用于计算所有候选区域成为跟踪目标的概率,取到概率最大值的候选区域即为跟踪目标。训练分类器的过程可以用以下数学公式描述:

$$\min_w \sum_i^n |f(X_i) - y_i|^2 + \lambda \|w\| \quad (3)$$

即找到最优的  $w$ , 使得代价函数(3)最小。

由文献[14]可知:

$$w = \sum_i a_i \varphi(X_i) \quad (4)$$

其中:  $a_i$  为对应训练样本  $X_i$  的系数;  $\varphi(x)$  是将训练样本  $x$  映射到高维度特征空间的函数,任意两个样本  $x$  和  $x^*$  在高维度

特征空间的相关性或相似度为  $\varphi^T(x) \varphi(x^*) = \kappa(x, x^*)$ , 其中  $\kappa$  为高斯核函数。

$$\kappa(x, x^*) = e^{-\frac{1}{2\sigma^2}(\|x\| + \|x^*\| - 2\mathcal{F}^{-1}(\mathcal{F}(x) \odot \mathcal{F}(x^*)))} \quad (5)$$

其中:  $\mathcal{F}$  为离散傅里叶变换;  $\mathcal{F}^{-1}$  为离散傅里叶逆变换。由所有训练样本  $P^i x (i = 0, 1, \dots, n-1)$  构造核矩阵  $K$ ,  $K$  的元素  $K_{ij} = \kappa(X_i, X_j)$ , 由文献[12]可得:

$$a = (K + \lambda I)^{-1} y \quad (6)$$

其中  $a = [a_1 \ a_2 \ \cdots \ a_n]$ , 对式(6)进行傅里叶变换:

$$\mathcal{F}(a) = \hat{a} = \frac{\mathcal{F}(y)}{\mathcal{F}(k^{xx}) + \lambda} \quad (7)$$

其中:  $\hat{a}$  为  $a$  的离散傅里叶变换;  $k^{xx}$  为核矩阵  $K$  的第一行向量。于是训练分类器的过程从寻找最优  $w$  转化为寻找最优  $a$ 。

### 1.3 快速检测

对于新输入的图像区域  $z$ , 其为目标的概率大小为:

$$y' = \sum_i a_i \kappa(X_i, z) \quad (8)$$

KCF 同样对新输入的图像  $z$  进行循环移位操作来构造候选区域样本集  $P^{i-1} z$ 。定义  $K^z = \kappa(P^{i-1} z, P^{i-1} x)$ , 由文献[12]可知  $K^z$  满足循环矩阵的条件:

$$K^z = C(k^{xz}) \quad (9)$$

其中  $k^{xz}$  为  $K^z$  矩阵的第一行, 从而得到输入图像  $z$  在所有候选区域位置处成为跟踪目标的概率分布  $f(z)$ 。

$$f(z) = \mathcal{F}^{-1}(\mathcal{F}(k^{xz}) \odot \hat{a}) \quad (10)$$

可知  $f(z)$  为  $1 \times n$  向量, 其元素值对应所有候选区域成为跟踪目标的概率值,  $f(z)$  取到最大值的元素所对应区域即为跟踪目标。

### 1.4 外观模型更新

在快速检测后得到新的目标区域  $x'$ , 对  $x'$  进行循环移位构造新的训练样本集合, 以更新下一帧中用于分类器检测过程中用到的模型参数  $a$ 。

$$a = (1 - \beta) a_{\text{pre}} + \beta a_{x'} \quad (11)$$

其中:  $\beta$  为更新模型的学习率;  $a_{\text{pre}}$  由前一帧训练样本图像  $x$  通过分类器训练得到;  $a_{x'}$  由当前新的目标区域  $x'$  通过分类器训练得到。在传统的 KCF 算法中  $\beta$  为一固定常量, 然而这是非常不合理的, 因为当目标受到遮挡时, 应该停止对分类器模型的更新, 以增强跟踪算法的可靠性。所以在本文提出的方法中, 对  $\beta$  的取值作如下处理:

$$\beta = \begin{cases} 0.02, & \text{非遮挡} \\ 0, & \text{遮挡} \end{cases} \quad (12)$$

即当目标受到遮挡时, 停止模型的更新。

## 2 改进的多尺度 KCF 跟踪算法

KCF 跟踪算法利用循环结构的核函数计算候选区域  $P^i z (i = 0, 1, \dots, n-1)$  和训练样本  $x$  的相似度, 同时利用离散傅里叶变换将复杂的卷积计算转化为简单的频域相乘, 提升了跟踪器性能。在文献[15]评估中达到了最高的准确度和运行速度。然而传统的 KCF 跟踪算法采取固定大小的训练样本图像来训练分类器模型, 难以对目标运动过程中出现的尺度变化进行相应的处理, 最终导致分类器模型误差累计, 跟踪目标漂移。为此, 本文将使用相关滤波器(CF)对 KCF 算法进行多尺度跟踪上的改进, 并提出了一种遮挡检测机制, 用于判断目标是否出现遮挡。由先验知识可知, 当目标出现遮挡时, 不会同时有尺度上的变化, 跟踪目标因横向运动上的遮挡而停止在纵向上的移动, 其中纵向上的移动是造成跟踪目标尺度变化的主要原因。一旦检测到遮挡, 将停止对跟踪目标在尺度

空间上的估计,同时停止对分类器模型进行更新。

### 2.1 尺度估计

为实现多尺度的目标跟踪,必须对当前跟踪目标的尺度有准确的估计。定义当前 KCF 算法得到的目标区域为  $x''$ ,对  $x''$  进行多尺度变换建立尺度金字塔图像,记金字塔图像的第  $i$  层为  $I_i = s_i \cdot x''$ ,  $s_i \in \{s_1, s_2, \dots, s_l\}$ , 其中  $s_i$  为尺度变换因子,  $l$  为尺度空间的维度,即尺度金字塔图像的层数。设  $f_i$  为对区域  $I_i$  提取的 HoG 特征。由相关滤波器<sup>[16]</sup> 知识可知,用于尺度估计的相关滤波器模板  $h$  的频域表达式为  $H = \mathcal{T}(h)$ , 计算式如下:

$$H = \frac{\sum_{i=1}^l G_i \odot F_i^*}{\sum_{i=1}^l F_i \odot F_i^*} \quad (13)$$

其中:  $h$  为  $1 \times l$  向量;  $F_i = \mathcal{T}(f_i)$ ;  $F_i^*$  为  $F_i$  的共轭;  $G_i = \mathcal{T}(g_i)$ ,  $g_i$  为满足高斯分布的矩阵。

得到  $h$  后便可估计下一帧中经 KCF 算法得到的目标区域  $z$  的尺度,首先判断当前是否有遮挡,如果出现遮挡,记跟踪目标的尺度与上一帧中目标的尺度相同。如无遮挡出现,对  $z$  提取相应的 HoG 特征,记为  $k$ ,然后取  $\mathcal{T}^{-1}(\mathcal{T}(k) \odot H^*)$  最大值所对应的尺度  $s_i$  为跟踪目标的尺度,最后更新目标区域大小后按照式(13)重新训练尺度滤波器模板  $h$ 。

#### 算法 1 遮挡检测算法。

输入 候选区域为跟踪目标的概率分布  $f(z)$ , 候选区域坐标  $pos(z)$ , 样本  $z$  的高度  $height$ , 样本  $z$  的宽度  $width$ , 遮挡阈值  $\lambda_1$ , 面积因子  $\lambda_2$ ;

输出 表示是否受到遮挡的  $isOCC$ , 值为 1 表示受到遮挡, 值为 0 表示没有收到遮挡。

- 1) 求  $f(z)$  取到最大值的位置  $pos_{\max}(z)$  和  $f(z)$  的最大值  $f_{\max}(z)$ 。
- 2) 求取  $pos_{\max}(z)$  周围满足大于  $\lambda_1 \cdot f_{\max}(z)$  的所有点的位置  $pos_g(z)$ 。
- 3) 求取所有  $pos_g(z)$  点到  $pos_{\max}(z)$  的欧氏距离  $response_i = \|pos_g(z_i) - pos_{\max}(z)\|$ 。
- 4) 判断  $\sum_i response_i$  是否大于阈值  $\lambda_2 \cdot width \cdot height$ , 如果大于阈值, 则判断为受到遮挡; 否则判断为未受到遮挡。

### 2.2 遮挡检测算法

遮挡检测对分类器模型的更新和尺度估计过程中的相关滤波器模板  $h$  的更新过程至关重要。当出现遮挡时,对当前目标的尺度估计值可信度降低。传统的 KCF 算法本身未提供处理遮挡的机制。因此,本文从  $f(z)$  的概率分布进行研究,提出了一种基于  $f(z)$  的遮挡检测算法,算法描述如算法 1 所示。




图 1  $f(z)$  在遮挡下与未遮挡下的分布

假设目标受到遮挡的过程可看作是在原来跟踪的目标区域之上叠加了一个服从高斯分布的噪声,由于受到遮挡部分的区域也同样进行循环位移操作,在与分类器模型参数  $a$  作卷积时,导致  $f(z)$  在极大值周围点的提升  $\sigma$  变大,分布趋于

平滑。图 1 (a)、(c) 中矩形虚线框为传统 KCF 算法的目标跟踪结果,图 1 (b)、(d) 分别为图 1 (a)、(c) 中目标区域的  $f(z)$  分布,其中颜色越亮的区域所对应的  $f(z)$  概率值越大。可以看出当跟踪目标从未受到遮挡的图 1 (a) 运动到受到遮挡的图 1 (c) 时  $f(z)$  的分布变化趋势符合所作的假设。

## 3 实验结果与分析

为验证本文提出算法的效果,使用文献[15]中用到的评估方法。使用文献[15]中 28 个尺度变化幅度大的视频序列进行本文所提出跟踪算法 SKCF 的性能评估。使用两个评估性能的指标:第一个是精确度曲线 (precision curve)<sup>[10]</sup>,精确度曲线是指跟踪目标结果的坐标中心与真实人工标注的坐标中心欧氏距离小于某一阈值的帧数与整个测试视频序列图像长度的比值,一般选择曲线在阈值 20 像素处的精确度来对比不同的算法;另一个评估指标是 Pascal 视觉对象类率 (Pascal Visual Object classes Rate, VOR)<sup>[17]</sup>,VOR 是指跟踪目标与真实目标区域重合率为  $t$  ( $t \in [0, 1]$ ) 时的帧数与视频序列总长度的比率,一般选择重合率阈值为 50% 处的 VOR 值比较不同的跟踪算法。

与本文所提出的跟踪算法 SKCF 作对比的有核化的结构化输出 (Struck) 算法、核相关滤波器 (KCF) 算法、跟踪-学习-检测 (TLD) 算法、多示例学习 (MIL) 算法。

本实验环境配置如下: Matlab2013b, 奔腾处理器 T4200, 2 GHz 的 CPU 处理器, 3 GB 内存。实验参数  $\lambda_1$  取值 0.8,  $\lambda_2$  取值为 0.3 / 取值 33。

### 3.1 遮挡检测算法实验

为验证算法 1 的效果,本文使用跟踪目标在运动过程中受到遮挡的视频序列进行测试。选取的测试视频为文献[15]中的 jogging 视频序列。实验结果如图 2 所示,图 2 (a) 为 jogging 视频序列中目标刚刚受到遮挡的第一帧图像,其中跟踪目标由矩形虚线框标注。图 2 (a) 在整个视频序列中所对应的位置正好是图 2 (b) 中取到极大值的地方,图 2 (b) 的横坐标为测试视频序列的帧数,纵坐标为算法 1 的响应结果。可以发现,使用算法 1 可以检测目标在运动过程中是否受到遮挡,如果目标受到遮挡,后续的尺度估计过程中  $h$  的更新和分类器模型的更新过程采取相应的更新机制。




图 2 遮挡算法实验

### 3.2 对比实验

表 1 列出了对文献[15]中的 28 个有尺度变化的视频序列进行上述 2 个指标的评估结果。从表 1 可以看出本文所提出的算法的精确度在 5 个算法中排名最高,同时 VOR 也取到最大值。

表 2 为本文所提出的改进多尺度 KCF 算法 (SKCF) 和基准 KCF 算法在该 28 个测试视频上运行速度对比结果,从比较结果可知,虽然实验参数  $l$  取值 33,也即表示对跟踪目标进行 33 个尺度上的缩放,形成一个 33 层的图像金字塔,然而运行速度却只有原来的 40%,但仍然满足跟踪算法的实时性要求(每秒处理帧数在 15 到 20 帧都可视为实时性的跟踪)。图 3 为 5 种算法在 28 个测试视频上的精确度曲线和 VOR 曲线,可以看



出 SKCF 算法在 5 个算法中性能是最优的。表 3 为 5 种算法在 28 个测试视频上 *VOR* ,可以发现 SKCF 算法在一半以上的测试视频中取到了最大 *VOR* 。图 4 是 5 种算法在 car4、david、dog1、doll、carScale、singer1 测试视频上的部分运行效果图。从图 4 可以发现 本文提出的多尺度 SKCF 算法的跟踪结果随着目标的尺度变化而作出相应的变化 即随着目标的尺度变化而改变分类器训练样本的大小 从而提高了跟踪算法的准确度和重合度 而 KCF 算法却只能使用固定大小的窗口。

表 1 5 种算法的 *VOR* 和精确度比较结果 %

算法	<i>VOR</i> 中值	精确度中值	算法	<i>VOR</i> 中值	精确度中值
SKCF	85.0	92.9	KCF	41.10	84.8
MIL	26.0	38.2	Struck	41.93	68.8
TLD	49.5	90.9			

表 2 与基准 KCF 算法的运行速度对比

算法	平均每秒处理帧数
SKCF	29.8
KCF	72.9

表 3 28 个测试视频序列不同算法的 *VOR* 对比 %

算法	boy	car4	carScale	couple	crossing	david	dog1	doll	dudek	fleetface	freeman1	freeman3	freeman4	girl
SKCF	100.0	100.0	98.8	33.6	100.0	100.0	100.0	98.5	100.0	70.9	32.8	25.40	78.10	46.6
MIL	38.7	27.6	44.8	67.1	98.3	22.9	65.0	43.0	85.4	53.7	15.3	0.87	2.12	29.4
TLD	93.5	78.1	43.7	100.0	51.7	97.0	67.3	62.6	84.2	57.1	21.2	58.30	23.00	76.4
KCF	99.2	36.7	44.4	24.3	93.3	62.2	65.3	55.2	97.6	66.3	16.0	27.80	19.40	75.6
Struck	97.7	39.8	43.3	54.3	94.2	23.6	65.3	68.8	98.0	66.6	21.8	20.00	15.90	98.0
算法	Ironman	lemming	liquor	matrix	mRolling	shaking	singer1	skating1	skiing	soccer	trellis	walking	walking2	woman
SKCF	12.0	40.0	84.3	17.0	7.9	1.4	100.0	85.8	4.9	37.8	100.0	99.8	87.0	92.8
MIL	4.8	81.1	20.1	11.0	7.3	22.7	27.6	10.3	7.4	15.6	24.4	54.1	38.0	18.8
TLD	3.0	59.4	56.2	1.0	11.0	15.6	99.1	22.8	7.4	9.4	43.7	38.3	34.0	16.6
KCF	15.7	43.2	98.1	13.0	7.9	1.4	29.6	36.3	6.2	39.0	84.0	51.5	37.8	93.6
Struck	4.8	64.1	40.6	12.0	15.9	16.7	39.9	37.0	3.7	15.6	78.4	56.6	43.4	93.5



图 4 5 种算法不同测试视频上的部分跟踪结果

4 结语

针对 KCF 算法不能处理目标运动过程中出现的尺度变化问题 本文提出了一种基于相关滤波器和尺度金字塔图像的尺度估计机制;同时 为降低遮挡对尺度估计过程的影响 提高尺度估计机制的稳定性 提出了一种基于 KCF 分类器响

应的遮挡检测算法 遮挡检测算法利用循环移位图像和高斯噪声的特点通过简单有效的计算获取目标遮挡状态。实验结果表明 本文算法能有效地处理跟踪目标运动过程中出现的尺度变化问题。

参考文献:

[1] HOU Z, HAN C. A survey of visual tracking [J]. Acta Automatic

- Sinica, 2006, 32(4): 603–617. (侯志强, 韩崇昭. 视觉跟踪技术综述[J]. 自动化报, 2006, 32(4): 603–617.)
- [2] HARE S, SAFFARI A, TORR P H S. Structured output tracking with kernels [C]// Proceedings of the 2011 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2011: 263–270.
- [3] KALAL Z, MIKOLAJCZYK K, MATAS J. Tracking-learning-detection [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 34(7): 1409–1422.
- [4] BABENKO B, YANG M H, BELONGIE S. Robust object tracking with online multiple instance learning [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(8): 1619–1632.
- [5] ZHANG K, ZHANG L, YANG M H. Real-time compressive tracking [M]// ECCV 2012: Proceedings of the 12th European Conference on Computer Vision, LNCS 7574. Berlin: Springer, 2012: 864–877.
- [6] BOLME D S, BEVERIDGE J R, DRAPER B A, *et al.* Visual object tracking using adaptive correlation filters [C]// Proceedings of the 2010 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2010: 2544–2550.
- [7] ZHANG K, ZHANG L, YANG M H, *et al.* Fast tracking via spatio-temporal context learning [EB/OL]. [2015-05-01]. <http://azad-project.ir/wp-content/uploads/2014/07/Fast-Tracking-via-Spatio-Temporal-Context-Learning.pdf>.
- [8] HENRIQUES J F, CASEIRO R, MARTINS P, *et al.* Exploiting the circulant structure of tracking-by-detection with kernels [C]// ECCV 2012: Proceedings of 12th European Conference on Computer Vision, LNCS 7575. Berlin: Springer, 2012: 702–715.
- [9] DANELLJAN M, KHAN F S, FELSBERG M, *et al.* Adaptive color attributes for real-time visual tracking [C]// Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2014: 1090–1097.
- [10] van de WEIJER J, SCHMID C, VERBEEK J, *et al.* Learning color names for real-world applications [J]. IEEE Transactions on Image Processing, 2009, 18(7): 1512–1523.
- [11] LI Y, ZHU J. A scale adaptive kernel correlation filter tracker with feature integration [C]// Proceedings of the 13th European Conference on Computer Vision-ECCV 2014 Workshops, LNCS 8926. Berlin: Springer, 2014: 254–265.
- [12] HENRIQUES F, CASEIRO R, MARTINS P, *et al.* High-speed tracking with kernelized correlation filters [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(3): 583–596.
- [13] DALAL N, TRIGGS B. Histograms of oriented gradients for human detection [C]// CVPR 2005: Proceedings of the 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2005: 886–893.
- [14] RIFKIN R, YEO G, POGGIO T. Regularized least-squares classification [C]// Advances in Learning Theory: Methods, Model and Applications, NATO Science Series Sub Series III Computer and Systems Sciences, Vol. 190. Amsterdam: IOS Press, 2003: 131–154.
- [15] WU Y, LIM J, YANG M. Online object tracking: a benchmark [C]// Proceedings of the 2013 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2013: 2411–2418.
- [16] BODDETI V N, KANADE T, KUMAR B V K V. Correlation filters for object alignment [C]// Proceedings of the 2013 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2013: 2291–2298.
- [17] EVERINGHAM M, van GOOL L, WILLIAMS C K I, *et al.* The pascal Visual Object Classes (VOC) challenge [J]. International Journal of Computer Vision, 2010, 88(2): 303–338.

#### (上接第 3549 页)

- [10] YANG F, LU H, YANG M. Robust visual tracking via multiple kernel boosting with affinity constraints [J]. IEEE Transactions on Circuits and Systems for Video Technology, 2014, 24(2): 242–254.
- [11] ZHANG K, ZHANG L, YANG M. Real-time object tracking via online discriminative feature selection [J]. IEEE Transactions on Image Processing, 2013, 22(12): 4664–4677.
- [12] BOLME D, BEVERIDGE J, B DRAPER, *et al.* Visual object tracking using adaptive correlation filters [C]// CVPR 2010: Proceedings of the 2010 IEEE Conference on Computer Vision and Pattern Recognition. Washington, DC: IEEE Computer Society, 2010: 2544–2550.
- [13] HENRIQUES J, CASEIRO R, MARTINS P, *et al.* Exploiting the circulant structure of tracking-by-detection with kernels [C]// ECCV 2012: Proceedings of the 2012 European Conference on Computer Vision. Berlin: Springer, 2012: 702–715.
- [14] RIFKIN R, YEO G, POGGIO T. Regularized least-squares classification [M]// Advances in Learning Theory: Methods, Models and Applications. Amsterdam: IOS Press, 2003: 131–154.
- [15] MESSERSCHMITT D G. Stationary points of a real-valued function of a complex variable, UCB/EECS-2006-93 [R]. Berkeley: University of California, EECS Department, 2006: 1–8.
- [16] KALAL Z, MIKOLAJCZYK K, MATAS J. Tracking-learning-detection [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 34(7): 1409–1422.
- [17] JIA X, LU H, YANG M. Visual tracking via adaptive structural local sparse appearance model [C]// CVPR 2012: Proceedings of 2012 IEEE Conference on Computer Vision and Pattern Recognition. Washington, DC: IEEE Computer Society, 2012: 1822–1829.
- [18] ADAM A, RIVLIN E, SHIMSHONI I. Robust fragments-based tracking using the integral histogram [C]// CVPR 2006: Proceedings of the 2006 IEEE Conference on Computer Vision and Pattern Recognition. Washington, DC: IEEE Computer Society, 2006: 798–805.
- [19] HARE S, SAFFARI A, TORR P H S. Struck: structured output tracking with kernels [C]// ICCV 2011: Proceedings of the 2011 International Conference on Computer Vision. Piscataway: IEEE, 2011: 263–270.
- [20] WU Y, LIM J, YANG M. Online object tracking: a benchmark [C]// CVPR 2013: Proceedings of the 2013 IEEE Conference on Computer Vision and Pattern Recognition. Washington, DC: IEEE Computer Society, 2013: 2411–2418.